


컴퓨팅 패러다임의 본질적 변화

과거의 패러다임




검색 중심 컴퓨팅 (Retrieval-based)

출력물: 저장된 파일 및 데이터의 단순 조회

인프라: 정보를 안전하게 보관하는 '데이터 센터'

미래의 패러다임




생성 중심 컴퓨팅 (Generative-based)

출력물: 지능의 최소 단위인 '토큰(Token)' 실시간 생산


인프라: 지능을 대량 생산하는 '토큰 팩토리'

핵심 인사이트: 지난 2년간 컴퓨팅 수요는 10,000배 증가. 우리는 1,000,000배의 수요 폭발이 일어나는 '추론의 변곡점(Inference Inflection)'에 도달했습니다.

토큰 팩토리의 원자재: 데이터 파이프라인의 융합



토큰 팩토리의 경제학: 전력당 생산량의 한계 돌파




팩토리 경제학의 법칙: 1 Gigawatt로 제한된 물리적 전력 환경에서는, 칩의 개별 가격이 아닌 '전력당 토큰 생산 단가'가 곧 비즈니스의 최종 수익(Revenue)을 결정합니다.

Vera Rubin 플랫폼: 에이전틱 AI를 위한 팩토리 설계도

NVLink 72 & NVFP4

260 TB/s의 대역폭과 새로운 정밀도 연산. 단일 랙에서 3.6 엑사플롭스(Exaflops)의 단일 슈퍼컴퓨터 구현.






100% 완전 수랭식 (Liquid Cooled)

45°C 온수를 활용한 냉각. 기존 데이터 센터 칠러(Chiller)의 전력 부담을 없애고 컴퓨팅 전력으로 전환.

케이블리스 설계 (Disaggregated)

수만 개의 복잡한 케이블을 완벽히 제거한 백플레인 구조. 기존 2일이 소요되던 설치 시간을 단 2시간으로 단축.


프로세서 트로이카: Dynamo 소프트웨어로 통합된 삼각 편대

Vera CPU (툴 사용 및 조정자)	Rubin GPU (대규모 추론 및 컨텍스트)	Grok LPU (초고속 토큰 생성기)
		
역할: AI 에이전트의 초고속 토큰 사용(브라우저, 코드 실행 등) 지원. 특징: LPDDR5 메모리 탑재. 세계 최고 수준의 단일 스레드 성능.	역할: 거대 모델의 Attention 연산 및 복잡한 컨텍스트 추론. 특징: 288GB 거대 메모리. 방대한 KV 캐시(KVCache) 저장 공간 제공.	역할: 지연 시간을 극단적으로 낮춘 초고속 토큰(Decode) 생성. 특징: 대규모 온칩 SRAM 기반의 정적 컴파일(Statically Compiled) 혁신 아키텍처.



NVIDIA Dynamo OS: 이 세 가지 칩의 역할을 실시간으로 분배(Disaggregated Inference)하여 거대한 팩토리를 단일 시스템처럼 가동하는 마스터 운영체제.

팩토리를 짓기 전의 팩토리: NVIDIA DSX (Digital Twin)



1 Gigawatt 규모의 팩토리 구축에는 50조 원이 소요됩니다.
낭비되는 전력은 곧 수백억 원의 매출 손실입니다.


1. SIM (설계 및 시뮬레이션)

물리적 장비를 배치하기 전 열, 전력, 네트워크 병목을 Omniverse에서 사전에 완벽히 테스트.



2. EXCHANGE (자산 연동)

전 세계 장비 제조사들의 물리적 데이터를 디지털 트윈 스펙으로 통합.




3. FLEX (전력 라우팅)

지역 전력망(Grid)의 상태를 실시간으로 파악하여 등적 전력 조율



4. MAX-Q (실시간 최적화)

AI 에이전트(Phaedra)가 가동 중인 팩토리의 냉각과 연산을 초 단위로 자동 통제



소프트웨어의 캄브리아기 대폭발: OpenClaw (The OS Moment)

인터넷 시대
(Internet Era)

HTML / HTTP
(웹의 연결)

클라우드 시대
(Cloud Era)

Linux / Kubernetes
(인프라의 표준화)

에이전트 시대
(Agentic Era)


OpenClaw
(지능의 운영체제)

세계 최대의 오픈소스 AI OS

- ✓ 인류 역사상 가장 빠르게 성장한 오픈소스 프로젝트 (단 3주 만에 Linux의 30년 기록 돌파).
- ✓ 단순한 챗봇을 넘어 스스로 계획(**Reasoning**)하고 도구(**Tool**)를 조작.
- ✓ 하위 에이전트를 자율적으로 생성하고 복잡한 워크플로우를 스케줄링.

기업용 에이전트 보안의 완성: NemoClaw


문제: 에이전트는 사내 민감 데이터에 접근 하고 코드를 실행합니다. 이는 기존 보안 체계에 치명적인 위협입니다.



핵심 요약: NemoClaw는 오픈소스 에이전트의 무한한 잠재력을 기업의 엄격한 보안망(Reference Design) 안에서 가장 안전하게 구동하는 유일한 해법입니다.

기업 IT 패러다임의 진화: SaaS에서 GaaS로

과거 (SaaS - Software as a Service)



특징: 소프트웨어는 수동적인 도구에 불과하며, 인간이 모든 세부 워크플로우를 주도해야 합니다.


미래 (GaaS - Agentic as a Service)



특징: 모든 소프트웨어 기업은 자율적으로 일하는 맞춤형 에이전트를 대여하는 '토큰 제조업체'로 진화합니다.

미래의 채용 조건: 앞으로 엔지니어 채용 계약서에는 연봉뿐만 아니라, 생산성을 10배 높여줄 '연간 토큰 예산(Token Budget)'이 포함될 것입니다.


특화된 두뇌들의 집합: NVIDIA 오픈 모델 생태계



단일 모델이 세상을 지배할 수는 없습니다. NVIDIA는 모든 산업이 자신만의 특화된 AI 두뇌를 구축할 수 있도록 최상위 파운데이션 모델을 개방합니다.

디지털을 넘어선 물리적 AI (Physical AI & Robotics)

문제: 로봇에게 컴퓨팅은 곧 데이터입니다. 하지만 물리적 로봇을 훈련시키기 위한 현실 세계의 데이터는 턱없이 부족하고 위험합니다.



합성 데이터 생성

Cosmos와 Isaac Lab을 통해 가상 공간에서 무한대의 훈련 데이터 자체 생성.


물리 시뮬레이션

Newton 물리 엔진이 중력, 마찰 등 현실의 물리 법칙을 완벽히 모사 (디즈니 Olaf 로봇 보행 훈련 성공).

현실 적용


Alpamayo 모델이 탑재된 BYD, Uber 파트너십을 통한 실제 도로 주행 및 산업용 로봇 제어 적용.

수직 통합과 수평적 개방 (Vertical Integration, Horizontal Openness)



우리는 특정 애플리케이션의 극한 최적화를 위해 수직적으로 통합하지만,
전 세계 누구나 이 혁신을 사용할 수 있도록 모든 클라우드에 수평적으로 개방합니다.

총체적 청사진: 5계층 AI 생태계의 완성



컴퓨팅의 재발명, 다가온 1조 달러의 기회

\$1,000,000,000,000+

(2027년까지 확정된 전 세계 AI 인프라 수요)

데이터 센터는 이제 지능을 생산하는
공장으로 변모했습니다.

비즈니스의 미래는 전력당 가장 저렴하고
똑똑한 '토큰'을 생산하는 것에 달려있습니다.

기업의 최우선 과제

당신만의 토큰 팩토리 인프라를 구축하고, OpenClaw 기반의
전사적 에이전트(Agentic) 생태계 전략을 즉시 수립하십시오.