


엔비디아 루빈(Rubin)의 진짜 혁신: 연산이 아닌 메모리 계층화

LPU, MoE, KV Cache로 풀어보는
AI 추론 병목의 정체와 해결책

0.5pt


- 단순한 연산력 강화를 넘어선 아키텍처 패러다임의 전환
- 철저하게 워크로드별로 분해된 모듈형 생태계의 완성



ARCHITECTURAL INNOVATION REPORT

OCTOBER 2024

플롭스(FLOPs) 만능주의의 종말



과거의 기준 (Compute)

초당 부등소수점 연산(FLOPs) 횟수 및 코어 수 중심의 설계




현재 AI 추론의 핵심 (Data Routing)

연산기보다 데이터를 읽고 옮기는 경로와 빈도가 전체 속도를 결정


새로운 병목: AI 추론 단계에서는 연산 속도가 아닌
데이터의 위치와 이동 경로가 시스템의 병목으로 작용합니다.

AI 추론의 이중성: 완전히 다른 두 개의 워크로드



프리필 (Prefill) 단계


- 대량의 프롬프트와 문서를 한 번에 병렬 처리
- 동시다발적 데이터 소화 역량
- 핵심 요구사항: 대규모 스루풋 (Throughput)



디코드 (Decode) 단계

- 토큰을 한 번에 하나씩 연속적으로 생성
- 이전 결과를 즉각 참조하여 다음 토큰 도출
- 핵심 요구사항: 초저지연 응답 속도 (Ultra-low Latency)

프리필 엔진: 거대 병렬 처리와 HBM의 영역



1 역할

프리필 단계의 거대 행렬 연산(Matrix Math) 및 디코드 어텐션 전담

2 데이터 특성

긴 시퀀스의 입력값을 수많은 토큰 간의 연관성으로 동시 계산

3 확장성

다중 사용자와 거대 모델의 컨텍스트를 동시 수용하는 메인 메모리

디코드 병목: '용량'이 아닌 '응답 속도'의 한계

짧은 반복 루프의 역설


토큰 하나를 생성할 때마다 전체 QKV 메모리를 참조해야 하며, 이 과정이 초당 수십 번 반복됨.

캐시 미스 (Cache Miss)의 치명상

한 번에 옮기는 데이터 대역폭이 아무리 커도, 데이터를 요청하고 가져오는 '대기 시간'이 길면 전체 생성 속도가 급감함.


새로운 하드웨어의 필요성

디코드 영역에서는 HBM의 스루풋보다, 즉각적이고 결정론적(Deterministic)으로 반응하는 특수 메모리 계층이 필수적.




LPU의 투입: 디코드 루프를 지배하는 온칩(On-chip) SRAM

DRAM / HBM 공정



LPU / SRAM 로직 공정




물리적 거리의 소멸

D램 공정이 아닌 컴퓨팅 코어와 동일한 로직 공정(Logic Process)으로 제조. 칩 내부에 바짝 붙어 있어 지연 시간(Latency)이 극단적으로 짧음.

디코드 전담 특수 부대

범용 칩이나 HBM의 대체재가 아님. 응답 지연에 극도로 민감한 디코드 루프만을 전담하기 위해 탄생한 극단적인 속도의 메모리 계층.

MoE 아키텍처의 딜레마: 폭발하는 '통신 병목'



Mixture of Experts (MoE)의 역설

각 토큰에 맞는 '전문가(Expert) 모델'만 부분적으로 활성화하여 연산량 자체는 획기적으로 줄어듦.


다이나믹 라우팅의 부하

연산은 줄었으나, 토큰을 어느 전문가 GPU로 보낼지 끊임없이 결정하고 분배하는 통신(Communication) 트래픽이 폭발함.

결과

네트워크 상에서 데이터가 얹히며 발생하는 지연(Delay)이 연산 그 자체보다 더 큰 병목으로 작용.

최강의 트래픽 컨트롤러: LPU의 진가



MoE 라우팅 전담

피드포워드 네트워크(FFN)와 전문가 실행(Expert Execution) 트래픽을 LPU가 전담 분담.

압도적 대역폭 활용


온칩 SRAM의 극단적인 대역폭을 통해 수많은 토큰의 분배와 회수를 지연 없이 일정한 속도로 처리.

매끄러운 파이프라인


통신 병목을 SRAM 계층에서 완벽히 흡수하여 전체 시스템이 끊김 없이 답변을 생성하도록 보장.

폭발하는 컨텍스트: 에이전트 AI와 장기 기억의 한계


단일 프롬프트 (Single Prompt)



멀티턴 추론 (Multi-turn Inference)



에이전트 AI (Agentic AI)




멀티턴과 에이전트 AI 시대의 도래

AI가 스스로 생각하고 여러 번 대화하며 작업을 수행함에 따라, 과거의 맥락과 히스토리를 저장하는 KV Cache 용량이 모델 자체의 크기를 압도적으로 초과하여 기하급수적으로 팽창함.

용량의 벽

GB 단위의 비싼 S램이나 초고속 HBM만으로는 이 거대한 장기 기억 데이터를 비용적, 물리적으로 감당할 수 없음.

CMX와 낸드(NAND) 플래시의 등판: 무한한 데이터 저장고



컨텍스트 메모리 (CMX)

블루필드(BlueField) DPU를 기반으로,
폭발하는 장기 KV Cache를 시스템
스토리지 영역으로 완벽하게 오프로딩.

낸드 플래시의 AI 인프라 편입

S램이나 D램에 비해 응답 속도는 느리지만,
끝없이 팽창하는 에이전트 AI의 히스토리를
저장할 수 있는 압도적인 대용량을 제공.

최대 5배 향상된
전력 효율 및 스루풋

분산된 계층을 하나로 묶는 패브릭: NVLink 6





통신망의 스케일업 (Scale-up)

극단적으로 세분화된 메모리 계층(SRAM, HBM, NAND)과 수많은 GPU가 마치 하나의 거대한 칩처럼 묶여 작동하도록 지원하는 핵심 인프라.


실시간 통합

거대 모델을 분산 처리하고 동기화할 때 발생하는 데이터 지연을 막고, 아키텍처 전체를 하나의 AI 생태계로 통합.

엔비디아 AI 메모리 트릴로지 (Trilogy) 매트릭스

	SRAM (LPU / LPX)	HBM (루빈 GPU)	NAND (CMX)
특징	로직 공정 기반 온칩 메모리	D램 공정 기반 3D 적층 메모리	플래시 스토리지 시스템
시각적 지표	 대역폭: 높음	 대역폭: 극단적 높음 (최고 강점)	 대역폭: 낮음
	 지연시간: 극단적 낮음 (최고 강점)	 지연시간: 중간	 지연시간: 높음
	 용량: 매우 낮음	 용량: 중간	 용량: 무한대 (최고 강점)
전담 워크로드	디코드 루프, MoE 라우팅, 전문가 실행	프리필 단계, 대용량 행렬 연산, 디코드 어텐션	에이전트 AI 히스토리, 초장기 멀티턴 KV Cache


통합 아크: 궁극의 '모듈형 AI 팩토리' 완성



하나의 완벽한 범용 칩은 존재하지 않는다.



루빈 아키텍처는 워크로드의 성격(Prefill, Decode, Context)을 철저히 분해하고, 각 단계의 병목을 완벽히 해소하는 맞춤형 하드웨어를 매칭한 거대한 생태계 시스템입니다.

AI 하드웨어의 새로운 법칙 (The New Rules)




연산(FLOPs)에서 통신(Communication)으로

AI 경쟁력의 핵심은 단순한 프로세서의 코어 속도가 아니라, 폭발하는 데이터가 머무르고 이동하는 아키텍처 통신 설계에 있다.



워크로드의 극단적 파편화

프리필과 디코드, MoE 통신과 에이전트 장기 기억 등 성격이 판이하게 다른 작업은 이제 하나의 범용 칩이 아닌, 철저히 분리된 전용 메모리 계층(SRAM, HBM, NAND)이 각각 나누어 전담한다.



소프트웨어 기반의 오케스트레이션

이토록 복잡하고 파편화된 다중 계층과 패브릭을 마치 하나의 칩처럼 엮어내어 통제하는 엔비디아의 통합 소프트웨어 및 컴파일링 역량이 진정한 해자(Moat)이다.

